

Нормализатор и классификатор: как это работает

Документ описывает идею простыми словами, без кода и без списка задач. Планы и задачи — в `plans/`, журнал экспериментов ML — в `ml/EXPERIMENTS.md`.

Зачем это нужно

У нас два потока данных, и они не стыкуются друг с другом.

Первый поток — архив закупок из `task/data`. Там есть то, что покупали: название позиции и официальный код ОКПД2. Кода там много, он надёжный, потому что его проставил заказчик.

Второй поток — то, что мы сами собрали парсерами с сайтов и каталогов поставщиков. Там есть цена, бренд, артикул, ссылка на страницу и иногда характеристики. Но нет ни кода ОКПД2, ни единицы измерения, а тип позиции у всех записей стоит «товар», потому что парсер пишет его константой.

Получается, у одного потока есть смысл позиции, у другого — её цена и продавец. Пока они живут в разных формах, их нельзя соединить: мы не можем ответить на вопрос «кто продаёт то, что сейчас покупают».

Нормализатор приводит обе стороны к одной форме. Классификатор проставляет позициям категорию, чтобы их можно было сравнивать и группировать.

Что мы видим в данных сейчас

Короткий срез по собранным предложениям, чтобы было понятно, с чем работаем:

- актуальных предложений около девяти тысяч, у всех стоит тип «товар»;
- кода ОКПД2 нет ни у одного;
- единицы измерения нет ни у одного, хотя у части записей единица лежит внутри характеристик строкой «Единица товара: Штука»;
- цена есть примерно у трети — только там, где источник отдаёт прайс;
- категория источника есть у пятой части, и это обрывок хлебных крошек без пути: «Стальные», «Плоские», «Для безударных и ударных». Сами по себе такие подписи ничего не значат;
- характеристики есть только у одного источника, и ключи в них плавают: рядом встречаются «Длина» и «Длина, мм», «Вес, кг» и «Вес нетто»;
- у трети названий в конце висит артикул, приклеенный к тексту;
- встречаются числа, испорченные Excel: вместо «1.79» в данных лежит «янв.79»;
- у компаний часто вместо названия стоит рекламная строка каталога, вроде «Детская и взрослая одежда, опт-розница»;
- ОКВЭД не заполнен ни у одной компании.

Всё это и есть работа нормализатора: не «красивее оформить», а сделать данные пригодными для соединения и поиска.

Единая форма: товар живёт в одном месте

Идея простая. Любая позиция — из архива, из прайса, из каталога компании или из запроса пользователя — превращается в запись одного и того же вида. Все такие записи ссылаются на один общий товар в каталоге.

То есть «Бумага А4, 500 листов» существует в системе один раз. К ней прилипают: несколько предложений разных поставщиков с ценами, несколько строк из прошлых закупок, официальный код ОКПД2 и человеческая рубрика «Канцтовары».

Это и даёт то, чего не может дать ни один поток по отдельности: код из закупок переносится на предложения поставщиков, а цены из предложений — на закупочные позиции. Нужная таблица в схеме ClickHouse уже есть (`catalog_items`), она пока пустая и как раз должна стать таким общим местом.

Как работает нормализатор

Это не одна функция, а цепочка шагов. Каждый шаг делает одну понятную вещь, у каждого своя версия. Исходные данные при этом никогда не затираются: нормализованные значения лежат рядом с оригиналом отдельными полями.

Шаг 1. Техническая чистка. Приводим символы к одному виду, убираем невидимый мусор и повторяющиеся пробелы, лечим кракозябры и испорченные Excel'ем числа, отделяем число от единицы.

Шаг 2. Разбор названия. Название поставщика — это обычно всё сразу: товар, бренд, размеры, ГОСТ и артикул в одной строке. Мы вытаскиваем всё лишнее в отдельные поля и оставляем ядро — что это за предмет. Например из «Сменный мини-валик 150 мм, ворс 12 мм СИБРТЕХ 80591» получаем предмет «валик малярный сменный», бренд «СИБРТЕХ», артикул «80591», а размеры уходят в характеристики.

Шаг 3. Слова к общему виду. Приводим слова к начальной форме, раскрываем сокращения («х/б», «в/с», «ПВХ», «шт»), сводим синонимы: «автошина», «покрышка» и «шина» должны стать одним и тем же.

Шаг 4. Характеристики к общему словарю. Все варианты записи одного свойства сводим к одному ключу: «Длина, мм», «Длина: 150 мм» и «длина 15 см» становятся одним полем «длина» со значением в миллиметрах. Список допустимых ключей — это справочник, а не что попало из источника.

Шаг 5. Единицы измерения. Переводим всё в официальный справочник ОКЕИ: «Штука» — это код 796, миллиметры сводим к метрам, граммы к килограммам. Без этого шага цены и количества просто несравнимы между собой.

Шаг 6. Цена. Фиксируем валюту, отметку про НДС, дату наблюдения и считаем цену за базовую единицу. «Упаковка 500 листов за 300 рублей» и «лист за 0,6 рубля» должны

сравниваться.

Шаг 7. Склейка дублей. Одинаковые товары от разных продавцов соединяем в одну карточку каталога. Сначала по жёсткому признаку — совпал бренд и артикул. Потом сравниваем похожие названия внутри небольших групп-кандидатов. Все встреченные варианты написания сохраняем как псевдонимы товара: они потом сами работают на поиск.

Как работает классификатор

Классификатор ничего не угадывает. Он проставляет код только тогда, когда может его обосновать, а в остальных случаях честно пишет «неизвестно». Это важная часть замысла: подготовка данных должна показывать дырки, а не замазывать их.

Код берётся по четырём каналам, в порядке надёжности. У каждой записи остаётся отметка, каким каналом её классифицировали.

Канал первый: код уже есть. В архиве закупок ОКПД2 проставлен заказчиком. Это самый надёжный источник, его мы просто берём как есть.

Канал второй: название совпало со справочником. Многие позиции названы дословно так, как они записаны в официальном классификаторе: «Услуги связи», «Крахмал картофельный», «Бензин автомобильный». Для таких достаточно поиска по справочнику ОКПД2 по нормализованному названию.

Канал третий: перенос кода через общий товар. Если нормализованное название предложения поставщика совпало с названием позиции из архива, у которой код уже есть, мы берём этот код. Это обычное соединение таблиц, а не предсказание — именно здесь архив и собранные данные начинают работать вместе.

Канал четвёртый: карта категорий источника. Для каждого сайта один раз составляется руками таблица соответствия: такой-то раздел каталога — такая-то рубрика и такая-то группа ОКПД2. Это обычный конфиг, который лежит в репозитории и правится глазами. Один раз составленная карта закрывает сразу тысячи позиций. Чтобы это заработало, парсеры должны отдавать полный путь по разделам, а не только последний: «Стальные» без родителя бесполезно, «Крепёж → Хомуты → Стальные» уже нет.

Запасной словарь. Отдельно держим словарь главных слов: «бумага», «ручка», «папка» — канцтовары; «футболка», «бейсболка», «халат» — одежда. Он помогает там, где не сработали первые каналы, и тоже заполняется руками.

Всё, что не закрылось ни одним каналом, остаётся без кода и попадает в отчёт. Этот остаток — понятная постановка задачи для ML, а не наша проблема, которую надо скрыть.

Два деления вместо одного

Деления на товары и услуги мало, поэтому мы ведём две разметки одновременно.

Код ОКПД2 — это машинная основа. Он иерархический, из четырёх уровней, и важно, что мы не обязаны всегда доходить до самого подробного уровня. Лучше сказать «класс 17,

бумага и бумажные изделия» и быть правым, чем выдать десятизначный код и ошибиться. Поэтому у кода всегда указан уровень подробности.

Рубрика — это человеческое деление для интерфейса: канцтовары, одежда и спецодежда, продукты питания, мебель, стройматериалы, электроника, медизделия, клининг, транспорт и ГСМ. Таких рубрик несколько десятков. Рубрика не считается отдельно и не угадывается: это таблица соответствия от верхних уровней ОКПД2 к рубрикам плюс несколько явных исключений. Благодаря этому рубрика всегда согласована с кодом, пересчитывается мгновенно и правится без переделки чего бы то ни было.

Тип позиции — товар, работа или услуга — тоже выводится из кода: строительные работы и услуги занимают в ОКПД2 свои диапазоны. Там, где кода нет, помогают шаблоны названия: «оказание услуг», «выполнение работ», «поставка». Так снимается текущая проблема, когда у всех собранных предложений стоит «товар».

У компании категория не одна. Мы складываем её позиции и получаем доли по направлениям: «спецодежда 70%, обувь 20%, средства защиты 10%». Туда же идут ОКВЭД из реестра и роль компании — производитель, дистрибьютор, продавец или исполнитель услуг.

Как данные остаются актуальными

Актуальность здесь двух видов, и путать их нельзя.

Свежесть источника. У каждого типа источника свой срок годности: прайсы обходим часто, каталоги компаний реже, реестр совсем редко. Обход идёт по очереди с приоритетом: раньше обновляем то, что давно не проверяли, что часто меняется и что часто спрашивают пользователи. Если страница не изменилась, повторно её не разбираем. Пропавшее предложение снимаем с продажи только после полного успешного обхода, чтобы одна сетевая ошибка не «удалила» половину каталога. В интерфейсе у каждой записи видно, когда её проверяли последний раз, и грубая отметка свежести: свежее, требует проверки, устарело.

Свежесть наших производных. Нормализация, классификация, карточка каталога — всё это посчитано из чего-то и какой-то версией правил. Поэтому у каждого производного значения хранится отпечаток исходных данных и версия алгоритма. Производное считается устаревшим в двух случаях: изменился исходник или изменились правила. Устаревшие попадают в очередь на пересчёт, и пересчитывается только они, а не всё целиком. Это же правило распространяется на эмбединги — там такой механизм в схеме уже заложен.

Отдельно живут справочники: ОКПД2, ОКЕИ, ОКВЭД, рубрики. Они меняются редко, но меняются, поэтому у них есть версия и даты действия. При обновлении справочника мы перепроставляем коды заново, а не затираем историю.

Как это собрано в коде

Нормализатор и классификатор — два отдельных сервиса, и джоба сбора не знает, как они устроены. Она просто вызывает их по договорённости: собрала пакет с источника, отдала

его нормализатору, получила обратно, отдала классификатору, получила обратно, записала. Порядок именно такой, потому что классификатор работает с нормализованным названием.

Благодаря этому любую из двух частей можно заменить целиком, и ни джоба, ни хранилище от этого не поменяются. В проверках на их место подставляются заглушки, и видно, что шаги вызываются в правильном порядке.

Сами правила лежат не в коде, а в файлах справочников рядом с ним: классы и группы ОКПД2, рубрики, словарь головных слов, карта разделов каталогов, единицы измерения и правила чистки текста. Их правят глазами, без переписывания программы. Когда появится полная официальная выгрузка ОКПД2, достаточно заменить файл.

Результат пишется в хранилище отдельными колонками рядом с исходными полями, и вместе с ним — версия правил, которыми он посчитан. Чтобы это соседство никого не путало, поверх таблицы лежит готовое представление: в нём у каждого смысла ровно одно поле — одно название, одна категория, одни характеристики, одна единица измерения. Читают его, а исходные колонки остаются в таблице для пересчёта и для ответа на вопрос «почему система так решила». По версии видно, какие записи устарели после правки словаря, и пересчитать можно только их. Отдельная команда пересчитывает уже сохранённые позиции, не трогая сбор.

Что получилось на наших данных

Проверено 1 октября 2026 года: хранилище очищено полностью и собрано заново — обход восьми источников занял одиннадцать минут, в базу легли 1,501 компания и 9,386 позиций. Нормализация и классификация прошли прямо во время обхода.

- нормализованы все позиции;
- код ОКПД2 и рубрику получили 56% — большую часть дал словарь головных слов, остальное карта разделов каталогов;
- 44% остались без кода честно, с пометкой «ни один канал не сработал»;
- единица измерения и цена за базовую единицу есть у 21%: только там, где источник публикует единицу сам;
- бренд распознан у 44%, артикул у 12%, характеристики приведены к общему словарю у 28%.

Проверка самих данных после прогона ничего плохого не нашла: нет позиций без нормализации, кода без рубрики, метода без кода, неверных кодов, отрицательных цен и перевёрнутых дат. Один источник выделяется: из пятисот его позиций распознаны девять, потому что вместо предмета он публикует название рисунка — «Бордовый», «Лучшей маме». Предмета в названии нет, и отказ здесь правильный.

Канал переноса кода из архива закупок сделан и проверен, но пока ничего не даёт: архив в хранилище ещё не загружен. После его загрузки он станет основным для товарных позиций, потому что это самый надёжный источник кодов.

Подробные числа и выбор настроек записаны в плане работ.

Где заканчивается наша часть

Мы отвечаем за данные и правила: единую форму записи, справочники и словари, четыре канала классификации, склейку дублей, свежесть и отчёт о покрытии. Всё это детерминированно — одинаковый вход даёт одинаковый выход, и для любого значения можно сказать, откуда оно взялось.

Дальше начинается ML, и это отдельная работа: предсказание кода для остатка, который не закрыли правила, эмбединги, поиск и ранжирование. Для неё мы готовим вход: пары «название — код ОКПД2» из архива как обучающую выборку с разбиением и контрольными суммами, и выборку позиций без кода как задачу. Наша метрика — это покрытие и полнота полей, а не качество модели.